📈 나만의 데이터로 미래를 예측하다

Orange3 선형 회귀 실습 보고서

— 두 변수의 관계를 스스로 찾아 예측 모델 만들기 —

학년 반 번호		이름		제출일 . . .

🎯 미션 우리 주변에는 '하나가 늘면 다른 하나도 규칙적으로 변하는' 관계가 많습니다. 공부 시간과 성적, 기온과 아이스크림 판매량, 팔로워 수와 좋아요 수처럼요. 이번 활동에서는 내가 직접 고른 두 변수(x, y)의 데이터를 모아 산점도를 그리고, 노코딩 머신러닝(ML) 도구 Orange3로 선형 회귀 예측 모델을 만든 뒤, 그 예측이 믿을 만한지 스스로 검증합니다.

🏆 이 보고서는 수행평가① **"Orange3 선형회귀 탐구"** 입니다. 만점 **30**점 · 기본점수**9**점 세 영역 각 10점(영역1·영역2·영역3)으로 채점합니다. ※ **AI(생성형 AI 포함)** 활용은 원칙적으로 금지합니다.

영역 1	데이터 이해 및 회귀식 추정	[10점]

📋 평가요소 (배점 근거)

① 선형 관계가 나타나는 탐구 주제·데이터를 목적에 맞게 선정하고, 독립·종속 변수의 관계를 올바르게 파악하였는가? → 1-1

② 산점도를 근거로 회귀식(y=ax+b)을 합리적으로 추정하였는가? → 1-2-1·1-2-2

③ 기울기·절편의 의미를 데이터 맥락에서 설명하였는가? → 1-3

1-1 탐구 주제와 데이터 정하기 (내 탐구 설계)

💡 어떤 관계를 예측해 볼까? 아래는 아이디어일 뿐입니다. 관심 분야에서 자유롭게 골라도 좋고, 직접 새로운 주제를 만들어도 됩니다.

분야	예시 주제 (독립변수 x → 종속변수 y)
일상·소비	기온 → 아이스크림(또는 음료) 판매량 · 광고비 → 매출액
학습·생활	공부 시간 → 시험 점수 · 수면 시간 → 집중도 자기평가 점수
사회·미디어	팔로워 수 → 게시물 좋아요 수 · 영상 길이 → 조회수
과학·환경	음료 온도 → 얼음 녹는 시간 · 용수철에 매단 무게 → 늘어난 길이
스포츠·건강	키 → 몸무게 · 연습 시간 → 기록(초·점수)

✅ 좋은 데이터의 조건

· 두 변수 모두 숫자(연속형)이고, 하나가 변하면 다른 하나도 대체로 함께 변하는 관계일 것

· 데이터 개수는 최소 8개 이상 (많을수록 회귀선이 안정적)

· 직접 측정·설문하거나 공공데이터(KOSIS·기상자료개방포털 등)에서 수집 — 출처를 반드시 기록

탐구 주제	우리나라 소프트웨어 산업 성장에 따른 IT 일자리 수요 예측
독립변수 **x**	연도별 소프트웨어 산업 매출액(단위:조원)
종속변수 **y**	연도별 소프트웨어 관련 종사자 수(단위:만명)
데이터 출처	코시스
예상 관계	x가 커지면 y는 증가할 것이다.

1-2-1 내 훈련 데이터 입력하기 (train.csv)

💡 수집한 훈련 데이터를 구글 시트나 엑셀에 입력하고 train.csv로 저장하세요. 첫 행은 변수 이름(x, y)으로 합니다.

독립변수 **x** (소프트웨어산업 매출액)	종속변수 **y** (소프트웨어산업 종사자수)
91	42
85	40
79	38
71	35
67	33
62	31
58	29
53	28

x (소프트웨어산업 매출액)	y (소프트웨어산업 종사자수)
91	42
85	40
79	38
71	35
67	33
62	31
58	29
53	28

1-2-2 규칙을 찾아 회귀식 손으로 추정하기

🧠 x가 일정하게 커질 때 y는 얼마씩 변하나요? 표에서 규칙을 찾아 직선의 식 $y = a\,x + b$ 로 손으로 추정해 보세요.

x가 한 단위 커질 때 y는 약 0.38만큼 증가한다. → 기울기 $a \approx 0.38$, 절편 $b \approx 7.1$.
따라서 $y = 0.38\,x + 7.1$ 로 예상한다.

1-3 기울기와 절편의 의미 해석

소프트웨어 산업 매출액이 1조 원 증가할 때마다, 종사자 수가 약 0.38만 명씩 늘어난다. 또한, 매출액이 0원일 때의 기본 종사자 수가 약 7.1만명을 의미한다.

영역 2	Orange3 예측 모델 구성	[10점]

📋 평가요소 (배점 근거)

① train-test 데이터를 적절히 구성하였는가? → 1-2(train)·2-1(test)

② 워크플로우(File→Scatter Plot→Linear Regression→Predictions)를 올바르게 연결하였는가? → 2-2

③ 모델의 예측값을 산출하고 실제값(손 계산)과 비교하였는가? → 2-3

2-1 내 테스트 데이터 만들기 (test.csv)

💡 훈련 데이터 범위 안에서 x값 5개 정도를 골라 테스트 데이터(test.csv)를 만드세요. y열은 비워 둡니다.

독립변수 **x**	종속변수 **y** (비움)
55	?
69	?
78	?
45	?
137	?

2-2 Orange3 워크플로우 구성하기

📌 워크플로우 순서

① File 위젯 → train.csv 불러오기 (이름: train data)

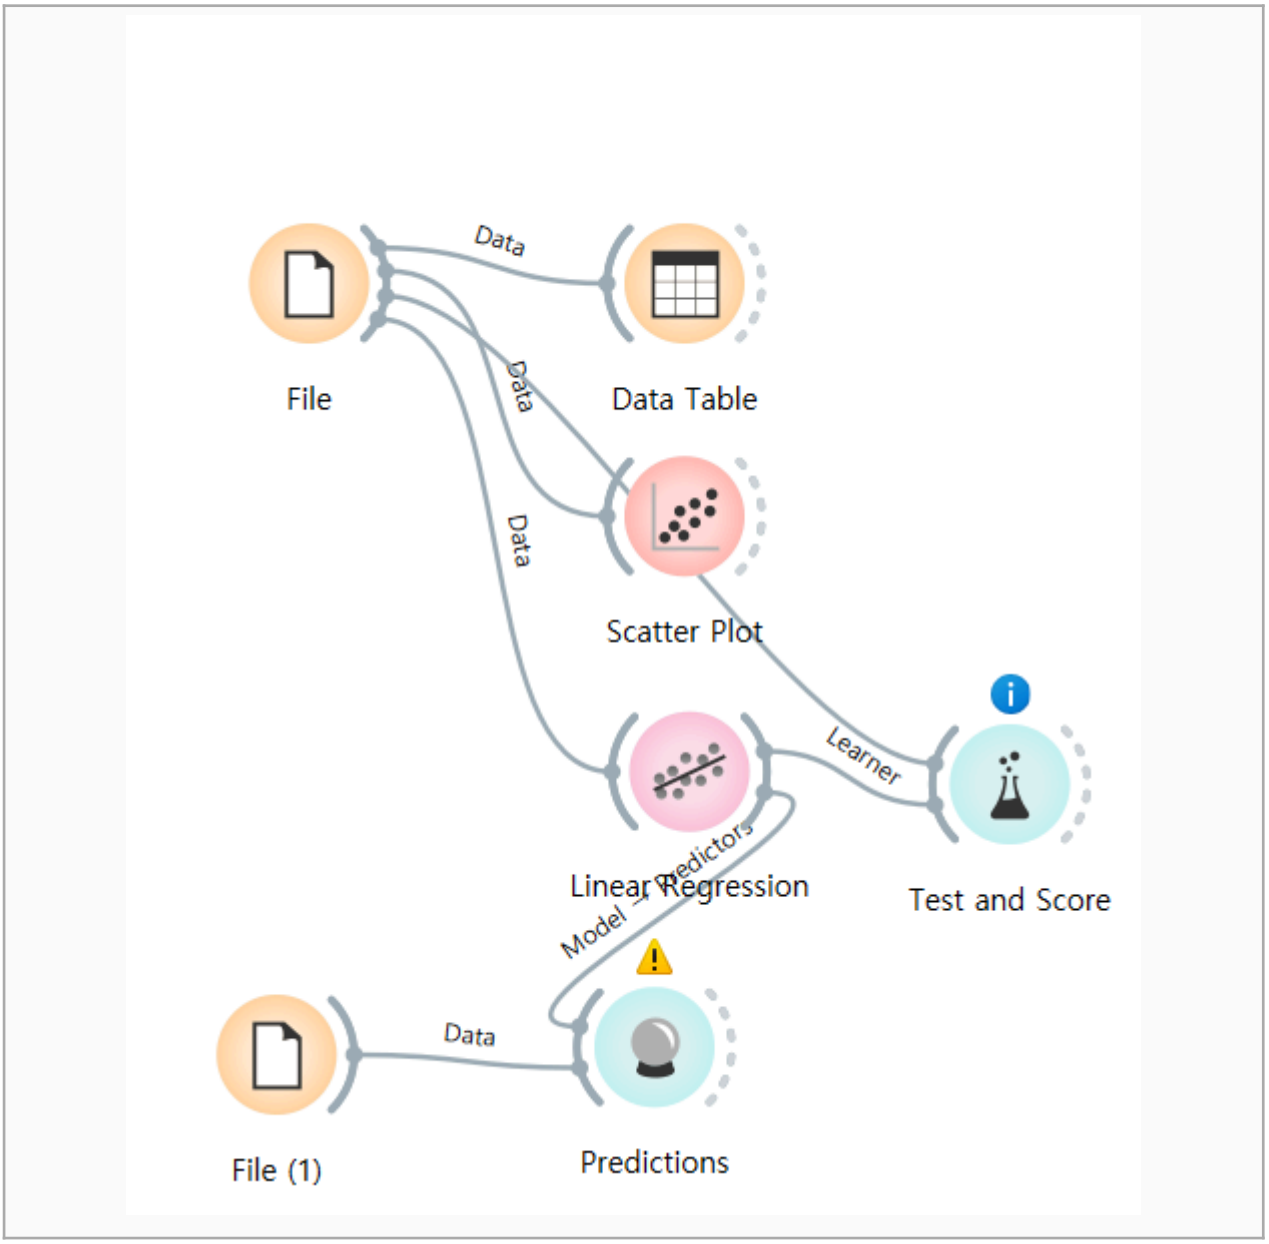
② Data Table 위젯 연결 → 데이터 확인

③ Scatter Plot 위젯 연결 → 산점도 확인 (x축: 독립변수, y축: 종속변수)

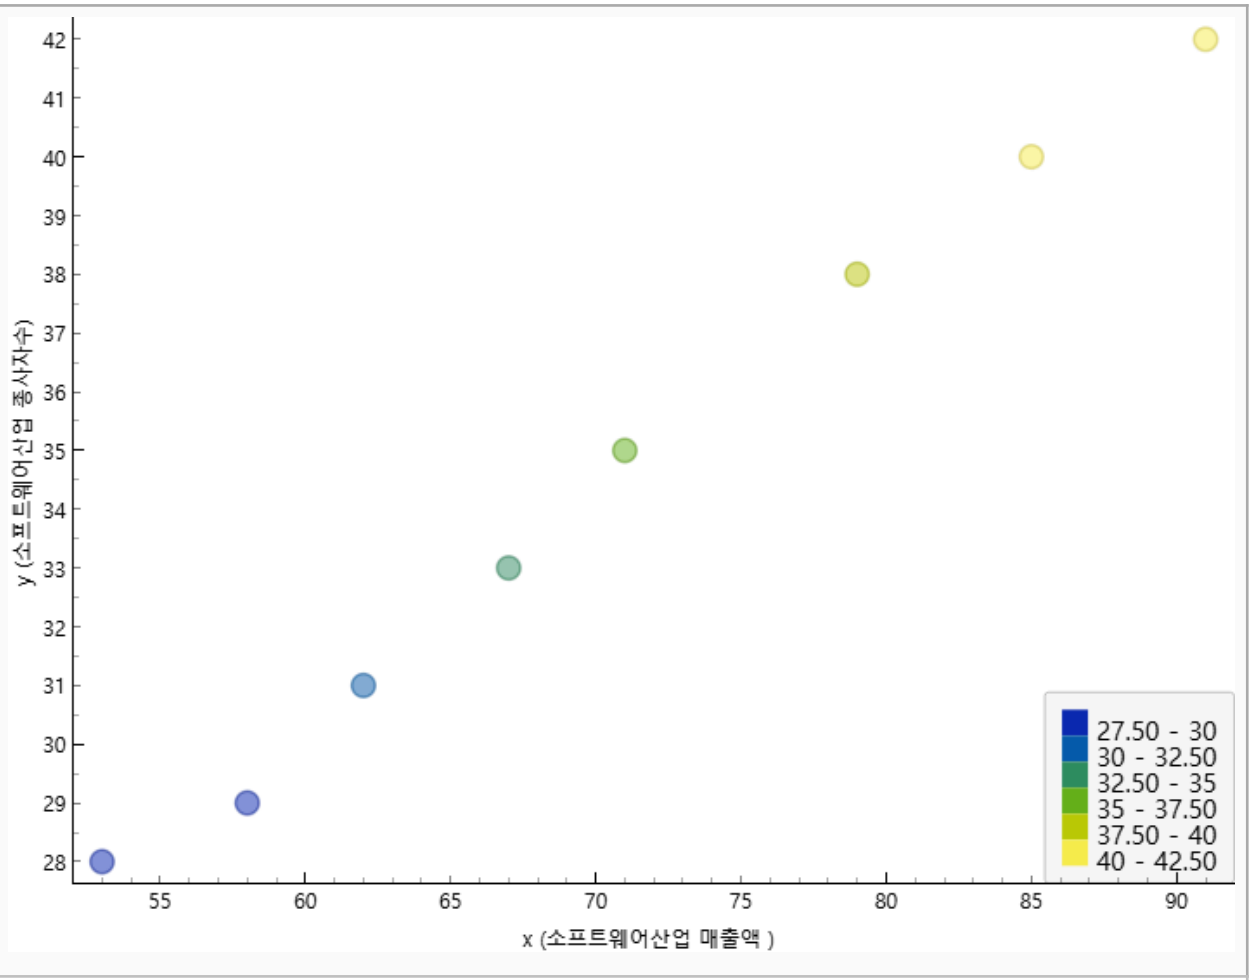
④ Linear Regression 위젯 연결 → 모델 학습

⑤ 새 File 위젯 → test.csv 불러오기 (이름: test data)

⑥ Predictions 위젯 → 모델 + 테스트 데이터 연결

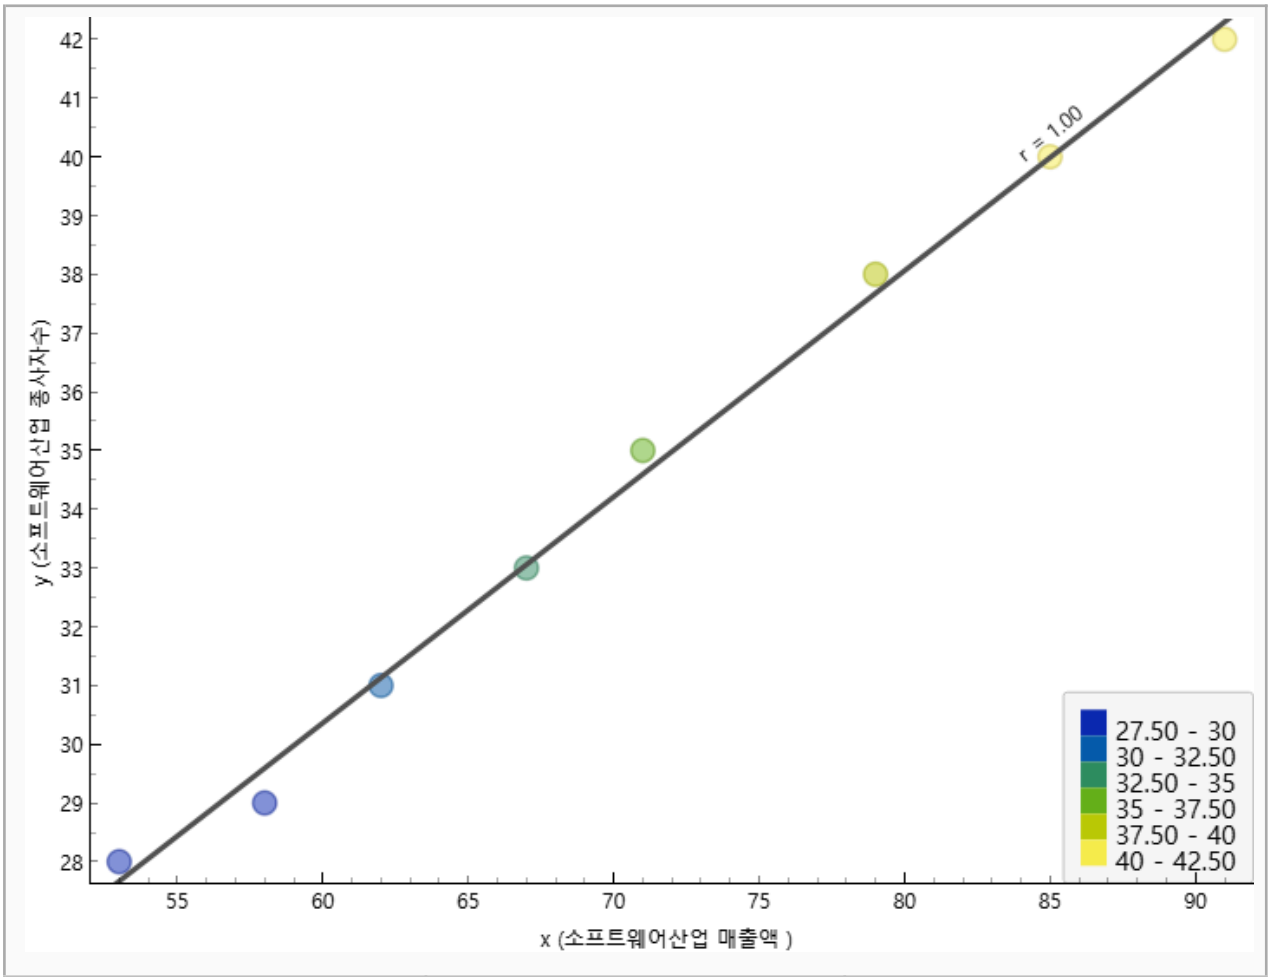

Data
File
Data Table
Data
Data
Scatter Plot
Learner
Linear Regression
Predictors
Model
Test and Score
Data
File (1)
Predictions

산점도 확인 및 관찰



데이터 점들이 왼쪽 아래에서 오른쪽 위로 향하는 뚜렷한 직선 형태를 띠고 있다. 따라서 두 변수는 양의 상관관계를 가진다고 볼 수 있다.

2-3 예측 결과 비교 (내 손 계산 vs Orange3)



x 값	내가 계산한 예측값 **(y=ax+b)**	**Orange3** 예측값
55	28	28
69	33.32	34
78	36.74	37
45	24.2	25
137	59.16	60

영역 3	결과 검증 및 해석	[10점]

📋 평가요소 (배점 근거)

① 회귀선과 평가지표(R²·MAE·RMSE)로 예측 결과의 타당성을 검증하였는가? → 3-1

② 정비례·반비례 등 관계의 방향과 의미를 데이터 맥락에서 해석하였는가? → 3-2

③ 모델의 한계(외삽의 위험)를 탐구하고, 활동을 통해 배운 점을 성찰하였는가? → 3-3·3-4

3-1 회귀선으로 타당성 검증

내 손으로 계산한 값과 Orange3의 예측값이 거의 비슷하게 나타났다. 산점도를 확인했을 때, 실제 데이터 점들이 회귀선 위에 아주 가깝게 붙어 있으므로, 이 모델이 소프트웨어 산업 성장과 일자리의 규칙을 훌륭하게 학습했다고 판단한다.

3-1-2 모델 평가지표로 신뢰도 검증 (Test and Score · 심화)

🌟 **(심화) Test and Score로 모델의 신뢰도를 '숫자'로 검증하기**

① **[Evaluate] → [Test and Score]** 위젯을 추가한다.

② **train data(File)를 Data로, Linear Regression을 Learner로 각각 연결한다.**

③ 평가 방법은 **Cross validation(교차검증, 기본값)**으로 두고 아래 세 지표를 읽어 기록한다.

(MSE·MAPE도 함께 나오지만 R²·MAE·RMSE에 집중. RMSE = MSE의 제곱근)

평가지표	내가 기록한 값	이 값이 뜻하는 것 (내 해석)
R² (결정계수)	0.989	모델이 실제 데이터의 변동을 99.6% 설명할 수 있다.
MAE (평균오차)	0.417	모델이 예측한 종사자 수가 실제 데이터와 0.417만명의 차이가 생긴다.
RMSE	0.517	예측을 크게 빗나가는 이상치가 거의 없이 안정적인 데이터임을 보여준다.

위 지표로 볼 때 내 모델은 얼마나 믿을 만한가요? 아래를 근거로 설명하세요.

① R²는 1에 얼마나 가까운가? (예측이 데이터를 잘 설명하는가)

② RMSE가 MAE보다 크다면, 그 이유는 무엇일까? (크게 빗나간 이상치)

③ [심화] Test and Score 점수는 '처음 보는 데이터로 시험 본' 교차검증 점수입니다. 전체 데이터에 그냥 맞췄을 때(훈련)보다 왜 조금 낮을까요?

3-2 결과 해석 — 숫자 뒤의 의미

x와 y는 뚜렷한 정비례 관계이다. 기울기가 양수라는 것은 산업이 1조 원 성장할 때마다 3,800여 개의 일자리가 창출된다는 뜻이다. 이 결과를 통해, 내가 희망하는 소프트웨어진로가 산업 발전과 함께 지속적으로 유망해질 것이라는 점을 데이터로 확인했으며, 진로를 선택하고 전문성을 기르는 데 긍정적인 확신을 얻을 수 있었다.

3-3-1 한계 탐구 — 극단값 실험 (외삽의 위험)

🤔 학습 데이터 범위를 크게 벗어난 x값을 회귀식에 넣으면 예측이 현실적으로 말이 될까요?

외삽(Extrapolation)의 위험을 확인해 봅시다.

극단적인 **x** 값	모델 예측값 **y**	현실적으로 가능한가**?**
90000000	34645866	x
0.1	7	x

회귀식에 따르면 매출액이 90000000일 때 종사자가 34645866이어야 하지만, 이는 전 세계 인구조차 초과하므로 현실성이 없다. 반대로 매출액이 0.1일 때 종사자가 7이나 남아있다는 것 역시 산업이 사실상 붕괴한 경제 상황과 맞지 않아 말이 되지 않는다. 선형 회귀는 우리가 학습시킨 데이터 구간 안팎에서만 신뢰할 수 있으며, 범위를 크게 벗어난 외삽은 인구의 물리적 한계나 AI 자동화 같은 미래의 외부 변수를 반영하지 못하는 한계가 있다.

3-3-2 활동 성찰

📝 활동을 돌아보며 이번 활동에서 '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지'와, 선형 회귀로 예측할 때 주의할 점(3-3의 외삽 실험과 연결)을 함께 정리하세요. 성실히 쓰면 세특(세부능력 및 특기사항) 작성의 좋은 소재가 됩니다.

📝 활동 성찰 — '어떤 문제 → 어떻게 해결 → 무엇을 배웠는지' 흐름으로 쓰면 세특 작성의 좋은 소재가 됩니다.

소프트웨어 산업 발전과 개발자 일자리 증가의 상관성을 막연한 전망이 아닌 객관적 데이터로 직접 증명하고 예측 규칙을 찾고자 했다. KOSIS에서 8개년의 소프트웨어 산업 매출액과 종사자 수 데이터를 수집하여 변수를 구조화한 뒤, Orange3로 선형 회귀 모델을 구축했다. 손으로 추정한 회귀식과 머신러닝 예측값을 비교하고 교차검증을 통해 결정계수와 오차 지표로 모델의 신뢰도를 정량적으로 평가했다. 단순한 수치 비교를 넘어 기울기와 절편의 맥락적 의미를 파악하며 데이터 리터러시를 배웠다. 특히, 극단값을 대입한 외삽 실험을 통해 학습 범위를 크게 벗어난 예측은 현실의 인구 한계나 AI 자동화 같은 외부 요인을 반영하지 못한다는 머신러닝의 근본적 한계를 봤다. 이를 통해, 알고리즘을 맹신하기보다 데이터의 유효 범위를 비판적으로 검토하는 분석적 태도의 중요성을 깊이 배웠다.

📚 핵심 개념 요약

· 지도학습 : 정답(레이블)이 있는 데이터로 모델을 훈련시키는 방법

· 회귀(Regression) : 연속적인 숫자 값을 예측하는 문제 유형

· 선형 회귀 : y = ax + b 직선으로 데이터의 패턴을 표현하는 알고리즘

· 기울기 a의 부호 : a>0이면 양의 관계(정비례), a<0이면 음의 관계(반비례)

· 외삽(Extrapolation)의 위험 : 학습 데이터 범위를 벗어난 예측은 신뢰하기 어려움

· 결정계수(R^2) : 모델이 데이터를 설명하는 비율(0~1). 단순 선형회귀에서는 상관계수의 제곱($R^2=r^2$)

· MAE / RMSE : 예측 오차의 크기(작을수록 좋음). RMSE는 큰 오차(이상치)에 더 민감

· 교차검증(Cross validation) : 데이터를 나눠, 학습에 쓰지 않은 부분으로 평가 → 모델의 '진짜 실력(일반화 성능)' 측정

· 훈련 vs 검증 성능 : 본 데이터엔 잘 맞고(훈련), 처음 보는 데이터엔 조금 못 맞음(검증). Test and Score 값이 검증 성능

🔎 수행평가 채점표 (교사 기입용)

채점 기준: 아래 참고

※ 저작권·데이터 윤리 미준수, 평가 윤리 미준수, AI 활용 금지 원칙 위반 등 부적절 상황 발생 시 해당 영역 0점 처리.

평가영역	배점	채점 기준 (해당 점수에 ○)	획득 점수
[영역1] 데이터 이해 및 회귀식 추정	10점	10 · 8 · 6 · 4	
[영역2] Orange3 예측 모델 구성	10점	10 · 8 · 6 · 4	
[영역3] 결과 검증 및 해석	10점	10 · 7 · 4 · 1	
합계	**30**점	기본점수 9점	**/ 30**